




공간 지능의 새로운 지평: 형태를 넘어 의미를 이해하는 3D AI

벡터 임베딩과 지식 그래프가 결합된
3D 멀티모달 프레임워크(SMKA) 및 탐색 경험 설계



단순한 3D 시각화의 한계

현존하는 3D 포인트 클라우드 스캔 데이터는 부분적이고(Partial), 노이즈가 많으며(Noisy), 밀집되어(Cluttered) 있습니다. 기하학적 특징만으로는 사물 간의 복잡한 상호작용과 숨겨진 관계를 파악할 수 없습니다.

공간의 '의미'와 '관계'의 이해


물리적 공간은 본질적으로 '계층적 구조(Hierarchical Structures)'를 갖습니다. 바닥은 책상을 지탱하고, 책상은 노트북을 지탱합니다. 기계가 이러한 '상식'을 활용하여 3D 공간을 하나의 **거대한 지식 네트워크**로 인식해야 합니다.

AI 지식 표현의 두 가지 축



벡터 임베딩 (Vector Embedding)

- 핵심 원리: 다차원 공간에서의 통계적/의미적 패턴 학습
- 강점: 미묘한 의미 차이 포착, 객체 간의 연속적인 '유사도' 계산
- 약점: 명시적인 관계 표현 부재, 추론 과정의 블랙박스화



지식 그래프 (Knowledge Graph)

- 핵심 원리: 노드(개체)와 엣지(관계)를 통한 명시적 사실 구조화
- 강점: 정확하고 설명 가능한 논리적 관계 추론, 위계 표현
- 약점: 새로운 관계 추론의 어려움, 높은 구축 비용

두 세계의 융합: 공간적 통합 원리

벡터 임베딩과 계층적 지식 그래프는 상호 보완적으로 작동하여 완벽한 공간 지능을 완성합니다.



역할 분담:

임베딩은 객체의 '특성적 유사성'을 계산하고, 지식 그래프는 객체 간의 '물리적·구조적 관계'를 정의합니다.

3D 공간에서의 중첩:

두 모델의 결과물은 동일한 디지털 트윈 공간 내에 중첩(Overlay)됩니다. 실제 객체의 위치 상공에 노드가 앵커링되며, 수직 높이(Z축)를 통해 물리적 위계가 부여됩니다.


3D Spatial Multimodal Knowledge Accumulation (SMKA)



기술적 난제를 해결하는 '상식'의 힘

3D 씬(Scene)의 객체들은 형태가 불완전하더라도, 그들의 의미적/공간적 배치에는 명확한 패턴이 존재합니다. SMKA 프레임워크는 외부 지식(ConceptNet)의 텍스트 사실(Textual facts)과 3D 시각 콘텐츠를 결합하여, 불확실한 시각 데이터 공간의 관계 예측을 명확하게 규제(Regularize)합니다.

Step 1. 계층적 기호 지식(Hierarchical Symbolic Knowledge) 초기화




외부 지식 필터링:

방대한 ConceptNet에서 3D 씬에 자주 등장하는 공통 객체 카테고리를 필터링하여 노드와 엣지 추출.

위계 및 구조화:

각 노드의 계층 토큰을 분류하고, 지지 대상을 기반으로 인접 레이어 간에 새로운 'Support Edge(지지 엣지)'를 추가하여 지식 그래프를 완성.

Step 2. 지식 기반 시각적 문맥 인코딩 (Visual Context Encoding)



1. 시각적 특징 추출:

Point Cloud Transformer(PCT)를 사용하여 3D 씬 내 각 객체의 공간적·시각적 특징 추출.

2. 계층적 시각 그래프 구축:


추출된 객체들을 계층 토큰에 따라 3D 공간상의 해당 레이어(Layer)로 라우팅.

3. 문맥 영역(Contextual Region) 그룹화:

같은 물리적 지지대를 공유하는 객체들은 기능적 역할이 비슷하고 근접해 있다는 '상식'을 바탕으로 시각적 특징을 상호 강화(Message Passing).

Step 3. 3D 공간 멀티모달 지식 결합 및 추론

텍스트 기반의 구조(KG)와 3D 시각 정보(Embedding) 간의 이질적 간극(Heterogeneous gap)을 해소하는 단계.



그래프 추론 네트워크: 시각 그래프의 문맥 특징과 기호 지식 그래프의 텍스트 팩트를 정렬.

메시지 패싱: 노드와 엣지가 그래프 구조를 통해 이웃으로부터 정보를 수집하고 상태를 반복적으로 업데이트(GRU).

최종 예측: 지식으로 강화된 문맥 특징을 통해 각 객체 쌍 간의 모든 가능한 관계 분포를 정규화하여 모호성 제거.

$$\text{GRU, update}_t = \text{GRU}(u, t_r)$$

$$\text{update}_t = \text{GRU}_{n+1}(x_i + h_t)$$

$$\text{update}_j = \text{GRU}_{en}(x_i + h_j)$$

$$\text{date}_t = \text{GRU}_{ek+1}(x_i - h_j^{/2}t)$$

$$j = \text{GRU}_n(z_j)$$

$$z_y = t\alpha(k_{\lambda u} + ET(t_i))$$

$$\text{GRU, update}_g = ET(x_i + h_k)$$

$$\text{update}_j = H(z_j - h_i)$$

$$\text{Complex graph}(j) = \frac{1}{n^{m_i}} \sum_{j=1}^N \frac{\nabla(\mathcal{K}_{(0.3,1)}, j)}{\ln((x_{ij} + \mathcal{E}_n))} + e^{\mathcal{K}_{\text{reh}}} + \alpha u_{\text{aersels}}$$

$$(\tilde{x}_i, j) = \frac{1}{n^{m_i}} \sum_{i=0}^N \sum_{k=1}^n \omega_{i,j}(\tilde{x}_i/h_j(u) + z))$$

$$u_{\text{grapn}} = u_{\text{xy}}\omega/p_i(h_i(z_i + x))$$

$$u_{\text{andol}} = \sum_{i=0}^N \sum_{k=1}^n \omega_{i,j}(\tilde{x}_i/h_j/h_j(u) + z))$$

$$1 + \frac{1}{\pi} \cdot \frac{\pi \cdot \pi \cdot \pi \cdot \pi}{\pi \cdot \pi \cdot \pi \cdot \pi}$$

복잡성에서 직관성으로:

3D 공간 임베딩 · 지식 그래프 탐색기 프로토타입

지금까지 살펴본 복잡한 멀티모달 지식 결합 파이프라인은 최종 사용자에게 노출되지 않습니다. 사용자는 단지 웹 브라우저에서 ‘마우스로 3D 공간을 클릭’하는 것만으로, 꼬리에 꼬리를 무는 데이터 관계 탐색과 숨겨진 임베딩 유사도 분석을 실시간으로 경험하게 됩니다.



웹 기반 3D 통합 탐색 프레임워크

단일 페이지 애플리케이션 내에서 모든 3D 궤도 회전(Pan/Zoom)과 데이터 동기화가 이루어집니다.

🔍 키워드 검색 (예: 노트북, 화장실)

3D 모델



래스터 투영



지식 그래프



📁 전체 공간

└ 📁 가구


└ 📁 사물



위계 경로

집 > 거실 > 소파 (ID: 001)

임베딩 특성



유사도 랭킹

1. 의자 (98%)

2. 테이블 (92%)

3. 책상 (87%)

2D 산점도 미니맵



시각적인 선(Link)을 통한 3D 관계 파악

그래프의 �지 스타일은 두 객체 간의 관계 속성을 직관적으로 은유합니다.

굵은 실선 (위계 관계 / Hierarchy):
수직적인 포함 구조.
(예: 방의 중심 상공에서 수직으로 내려와 바닥의 책상으로 연결)

가는 실선 (인접 관계 / Adjacency):
수평적이고 물리적인 이웃 관계.
(예: 책상과 바로 옆의 의자를 연결)

점선 (유사 관계 / Similarity):
임베딩 AI 모델이 산출한 의미적 특성의 유사성.
물리적 벽을 관통하여 특성이 비슷한 다른 공간의 사물을 연결.



꼬리에 꼬리를 무는 동기화된 탐색 경험



1. 탐색의 시작 (Click):

사용자가 3D 중앙 뷰에서 '화장실 A' 클릭.
카메라가 부드럽게 이동하며 주변
위계/인접 실선 하이라이트.

2. 임베딩 추론 패널 연동 (Auto-sync):

우측 패널의 '임베딩 유사도 랭킹' 즉시 계산.
물리적으로 멀리 떨어진 '화장실 B'가
최상단에 추천됨.

3. 공간 도약 및 새로운 추적 (Navigate):

화장실 B를 클릭하면 3D 시점이 즉시
플라이(Fly-to)하며, 패널 정보가 화장실 B의
지식 그래프 연관 노드들로 전면 갱신.

극한의 노이즈 환경에서의 압도적 강건성(Robustness)

실험 조건: 3DSSG 훈련 데이터셋에 랜덤하게 잘못된 관계(노이즈)를 점진적으로 주입.

원인과 해결: 텍스트 라벨에만 의존하는 기존 모델(KISG)은 노이즈가 높아질수록 성능이 급락. 반면, 당사의 프레임워크는 3D 씬 내부에 잠재된 신뢰할 수 있는 물리적 계층 구조(Floor-Table-Object)를 스스로 학습하여 대응.

성과: 무려 30%의 노이즈 라벨이 섞인 환경에서도 6.89% (R@50)의 획기적인 성능 격차를 유지하며 안정적인 관계 예측을 수행.



비전: 차세대 AI 시스템을 위한 통합 공간 지능

우리의 3D 공간 임베딩 및 지식 그래프 융합 프레임워크는 단순한 시각화 툴이 아닙니다.



Large Language
Models (LLM)



Autonomous
Robots



LLM의 환각 해결: GraphRAG와 결합하여, 대규모 언어 모델이 현실 세계의 정확한 3D 물리 법칙과 공간 구조를 이해하고 답변할 수 있도록 돕습니다.

컴팩트한 파운데이션 모델 (EPG): 무거운 공간 데이터를 가볍고 확장 가능한 표현으로 압축하여, 로봇의 실시간 네비게이션과 시각적 질의응답(VQA)을 지원합니다.

결론: 통계적 패턴(임베딩)의 유연함과 기호적 추론(지식 그래프)의 정확성이 만날 때, 인공지능은 비로소 인간처럼 공간을 이해하고 살아숨쉬게 됩니다.